

## SI221 Bases de l'apprentissage/Machine Learning for Pattern Recognition

### Décision bayésienne

Septembre 2018

Laurence Likforman-Sulem  
Telecom ParisTech/IDS Image, Données, Signal  
bureau : E 504  
likforman@telecom-paristech.fr



---

---

---

---


---

---

---

### Un exemple

histogramme pour 2 classes



L. Likforman - Telecom ParisTech - SI 221

2

---

---

---

---


---

---

---

### espace de représentation

2 paramètres :  $x_1$ ,  $x_2$



L. Likforman - Telecom ParisTech - SI 221

3

---

---

---

---

---

---

---

## théorie de la Décision

- approche par modélisation
- minimise globalement le risque d'erreur
  - connaissances sur les distributions sous jacentes

## Espace probabilisable: $\Omega$ , $F(\Omega)$

- $\Omega$  : espace des formes (épreuves)  
 $\Omega = \{\text{événements élémentaires}\}$
- $F(\Omega)$  : ensemble de parties de  $\Omega$   
événement = sous-ensemble de  $\Omega$  (partie de  $\Omega$ )

$\Omega$  est divisé en ensembles disjoints (les classes)  
 $\omega_1, \omega_2, \dots, \omega_k$  avec

$$\omega_i \cap \omega_j = \emptyset \quad \forall i \neq j$$

$$\bigcup_{i=1, K} \omega_i = \Omega$$

$\omega_1, \omega_2, \dots, \omega_k$  = système complet d'événements

## Espace probabilisé: $\Omega$ , $F(\Omega)$ , $P$

- $\Omega, F(\Omega)$  : est muni d'une probabilité  $P$
- $P : F(\Omega) \rightarrow [0,1]$

$$P(\Omega) = 1 \quad P(\emptyset) = 0$$

$$\forall A \quad 0 \leq P(A) \leq 1 \quad A \in F(\Omega): A \text{ événement, partie de } \Omega$$

$$\forall A, B \quad \text{si } A \cap B = \emptyset \text{ alors } P(A \cup B) = P(A) + P(B)$$

$$A, B \in F(\Omega) \times F(\Omega)$$

## Espace des classes, ensemble de caractéristiques

- espace des classes -> ensemble des étiquettes

$$J = \{1, 2, \dots, K\}$$

- espace de représentation -> ensemble des caractéristiques

$$\text{ex : } R = R^d$$

## variables/vecteurs aléatoires

- A chaque forme  $\omega$  sont associées :
  - variable aléatoire de classe :  $C(\omega)$   
 $C : \Omega \rightarrow J$
  - vecteur aléatoire correspondant à la réalisation  $x : X(\omega)$   
 $X : \Omega \rightarrow R^d$   
 $\omega \mapsto x$
- On observe la réalisation  $x$  de  $X$ , issue d'une forme de classe  $C$


## Fonction de décision

- on cherche la fonction de décision :  
 $d : R^d \rightarrow J$
- qui estime au mieux la classe, i.e.

$d(x)$  = estimation de la classe  $C(\omega)$  de la forme  $\omega$  dont la réalisation est  $X(\omega) = x$

### exemple : chiffres

$C : \Omega \rightarrow J$  l'opérateur idéal (v.a de classe)  
 $X : \Omega \rightarrow \mathbb{R}^d$  v.a associé à la représentation  
 $d : \mathbb{R}^d \rightarrow J$  fonction de décision



L. Likhoman - Telecom ParisTech - SI 221

10

### exemple : les planches de bois

$\Omega$  = ensemble des planches de frêne et de bouleau

$J = \{ 1 = \text{frêne}, 2 = \text{bouleau} \}$

$X =$  (indice de luminosité, indice relatif à la texture)

ensemble des caractéristiques :  $\mathbb{R}^2$

on a  $\omega_1 = C^{-1}(1)$        $\omega_2 = C^{-1}(2)$

L. Likhoman - Telecom ParisTech - SI 221

11

### Loi de probabilité associée à un vecteur aléatoire

- vecteur aléatoire  $X: \Omega \rightarrow \mathbb{R}^d$
- on probabilise  $\mathbb{R}^d$  par  $P_X$  (loi image)
  - $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d), P_X)$ : espace probabilisé
  - $\mathcal{B}(\mathbb{R}^d)$ : tribu des Boréliens (famille d'intervalles dans  $\mathbb{R}$ , de pavés dans  $\mathbb{R}^d$ )

- $P_X: \mathcal{B}(\mathbb{R}^d) \rightarrow [0,1]$

$$P_X(A) = P(X^{-1}(A)) = P(\{\omega \in \Omega \mid X(\omega) \in A\})$$


$$A \in \mathcal{B}(\mathbb{R}^d)$$

noté  $P(X \in A)$

L. Likhoman - Telecom ParisTech - SI 221

12

## Probabilité et loi de probabilité (loi image)



## fonction de répartition, densité de probabilité

- $F_X: \mathbb{R}^d \rightarrow [0,1]$

$$X = (X_1, X_2, \dots, X_d)$$

$$x = (x_1, x_2, \dots, x_d)$$

$$F_X(x) = P_X([-\infty, x_1] \times \dots \times [-\infty, x_d]) = P_X(X_1 \leq x_1, X_2 \leq x_2, \dots, X_d \leq x_d)$$

noté  $P(X \leq x)$

- densité de probabilité  $p_X$  associée à  $X$  ( $X$  admet une densité)

$$F_X(x) = \int_{[-\infty, x_1] \times \dots \times [-\infty, x_d]} p_X(u) du \quad \text{noté} \quad \int_{[-\infty, x_1] \times \dots \times [-\infty, x_d]} p(u) du$$

$$P_X(A) = P(X \in A) = \int_A p(x) dx \quad A \in \mathcal{B}(\mathbb{R}^d)$$

## densité de probabilité conditionnelle

- densités conditionnelles:

- $p(x | \omega_i) \quad i=1, \dots, K$

$$P_{X|\omega_i}(A) = P(X \in A | \omega_i) = \int_A p(x | \omega_i) dx \quad A \in \mathcal{B}(\mathbb{R}^d)$$

$$P(X \in A | C = i) \Leftrightarrow P(\{\omega | X(\omega) \in A \text{ sachant } C(\omega) = i\})$$

## densités de probabilités

- densités jointes

$$P_{XY}(A, B) = P(X \in A \text{ et } Y \in B) = \iint_{A, B} p(x, y) dx dy$$

$$P(X \in A, \omega_i) = \int_A p(x, \omega_i) dx = \int_A p(x | \omega_i) P(\omega_i) dx$$

- densités marginales

$$p(x) = \int_{\mathbb{R}^d} p(x, y) dy \quad p(y) = \int_{\mathbb{R}^d} p(x, y) dx$$

## Densités de probabilités (suite)

$$\int_{\mathbb{R}^d} p(x | \omega_i) dx = 1 \text{ et } \int_{\mathbb{R}^d} p(x) dx = 1$$

- densité mélange

$$p(x) = \sum_{i=1}^K p(x | \omega_i) P(\omega_i)$$

## probabilités a priori, a posteriori

- probabilité a priori de la classe  $i$  :  $P(\omega_i) = P(C=i)$

$$\sum_{i=1}^K P(\omega_i) = 1$$

- probabilité a posteriori

$$P(\omega_i | x) \Leftrightarrow P(C = i | X = x) \Leftrightarrow P(\{C(\omega) = i \text{ sachant } X(\omega) = x\})$$

$$\sum_{i=1}^K P(\omega_i | x) = 1$$

## formule de Bayes

$$P(\omega_i | x) = \frac{p(x | \omega_i) P(\omega_i)}{p(x)}$$

$P(\omega_i | x)$  : probabilité a posteriori

$P(\omega_i)$  : probabilité a priori

$p(x)$  : densité "mélange"

$$P(A|B) = P(A, B) / P(B)$$

$$P(A, B) = P(B|A)P(A)$$

## coûts de décision

- $\lambda(\omega_i | \omega_j)$  = coût de décider  $d(x)=i$  pour une réalisation  $x$  appartenant à la classe  $\omega_j$
- «classe» de rejet :  $\omega_0$   
K+1 décisions, K classes  
 $\lambda(\omega_0 | \omega_j)$  = coût de rejet  $j=1, 2, \dots, K$
- On cherche  $d$  : la règle de décision la moins coûteuse possible

## risques (1)

- risque conditionnel de prendre la décision  $d(x)=i$

espérance de la fonction  $\lambda$  :

$$C(d(x)=i | x) = C_i(x) = \sum_{j=1}^K \lambda(\omega_i | \omega_j) P(\omega_j | x)$$

- risque conditionnel associé à la décision  $d(x)$

$$C(d(x) | x) = \sum_{j=1}^K \lambda(d(x) | \omega_j) P(\omega_j | x)$$

## risques (2)

- risque associé à la règle de décision  $d$
- espérance du risque conditionnel

$$C(d) = \int_{R^d} C(d(x)|x) p(x) dx$$

## Règle optimale $d^*$

- $d^*$  est la règle qui minimise  $C(d)$
- > Pour chaque  $x$ , on minimise  $C(d(x)|x)$
- soit  $x$  donné, on décide  $d^*(x)=i$  si

$$C_i(x) = C(\omega_i|x) \leq C_j(x) = C(\omega_j|x) \quad j = 1, 2, \dots, K \text{ sans rejet}$$

$$j = 0, 1, 2, \dots, K \text{ avec rejet}$$

## risque Bayésien

- risque bayésien = risque moyen associé à la règle de décision  $d^*$  :
- espérance du risque conditionnel  $C(d^*(x)|x)$ :

$$C^* = E[C(d^*(x)|x)] = \int_{R^d} C(d^*(x)|x) p(x) dx$$

- les réalisations sont classées par la règle bayésienne du risque conditionnel minimum :

$$d^*(x) = \underset{i=0,1,\dots,K}{\text{Arg min}} C(\omega_i|x) \quad \text{et} \quad C^*(x) = C(d^*(x)|x) = \min_{i=0,1,\dots,K} C(\omega_i|x)$$

$$C^* = \int_{R^d} C^*(x) p(x) dx$$



## règle de Bayes à pénalisation symétrique

$$\begin{aligned} \lambda(\omega_0 | \omega_j) &= \lambda_r & \forall j=1, \dots, K \\ \lambda(\omega_i | \omega_j) &= 1 & \text{si } i \neq j \quad \forall j=1, 2, \dots, K \\ \lambda(\omega_i | \omega_i) &= 0 & \forall i=1, \dots, K \end{aligned}$$

Coût de rejeter  $x$  :  $C_0(x) = C(\omega_0|x) = \sum_{j=1}^K \lambda_r P(\omega_j|x) = \lambda_r$

Coût de décider  $\omega_i$  :

$$C_i(x) = C(\omega_i|x) = \sum_{j=1, j \neq i}^K P(\omega_j|x) = 1 - P(\omega_i|x) = P(C \neq i|x)$$

## décision

on décide  $d^*(x)=i$  si

$$C_i(x) = \sum_{j=1, j \neq i}^K P(\omega_j|x) = 1 - P(\omega_i|x) \leq C_j(x) \quad \forall j=1, 2, \dots, K$$

et si  $C_i(x) \leq C_0(x)$

On rejette si  $C_0(x) \leq C_j(x) \quad \forall j=1, 2, \dots, K$

Autre formulation :  $d^*(x)=i$  si  $P(\omega_i|x) \geq 1 - \lambda_r$  et  $P(\omega_j|x) \leq 1 - \lambda_r$   $\forall j=1, \dots, K$

Rejet si  $\max_{j=1, \dots, K} P(\omega_j|x) < 1 - \lambda_r$

## probabilités d'erreur conditionnelles

- $e^*(x)$ =probabilité conditionnelle d'erreur associée à la décision optimale  $d^*$

$$e^*(x) = P(\text{erreur}|x) = P(C \neq d^*(x)|x) = 1 - P(d^*(x)|x)$$

$$e^*(x) = 1 - \max_i P(\omega_i|x)$$

- $e_i(x)$  =probabilité conditionnelle d'erreur associée à la décision  $d(x)=i$  (optimale ou non)

$$e_i(x) = P(C \neq i|x) = 1 - P(C = i|x) = 1 - P(\omega_i|x)$$

### influence de $\lambda_R$

Seuil de rejet :  $0 \leq \lambda_R \leq \frac{K-1}{K}$

Espace de représentation :  $R = R_0 \cup R_A$

$$R_A = \bigcup_{i=1, \dots, K} R_i$$

Influence du seuil de rejet :

$$\lambda_1 \leq \lambda_2 \text{ alors } R_A(\lambda_1) \subset R_A(\lambda_2)$$

### probabilités acceptation/rejet

Probabilité de classement dans la classe  $\omega_i$   $P_{Ai} = \int_{R_i} p(x) dx$

Probabilité globale d'acceptation  $P_A = \int_{R_A} p(x) dx = \sum_{i=1}^K P_{Ai}$

Probabilité de rejet  $P_R = \int_{R_0} p(x) dx$

### probabilités d'erreur

Probabilité d'erreur de classement dans  $\omega_i$

$$P_{Ei} = \int_{R_i} e^*(x) p(x) dx$$

avec  $e^*(x) = P(\text{erreur} | x)$

Probabilité globale d'erreur :  $P_E = \int_{R_A} e^*(x) p(x) dx$

## probabilité de bon classement

Dans la classe  $\omega_i$  :

$$P_{C_i} = \int_{R_i} (1 - e^*(x)) p(x) dx$$

Probabilité globale de bon classement

$$P_C = \int_{R_A} (1 - e^*(x)) p(x) dx = \sum_{i=1}^K P_{C_i}$$

## Suite...

On a :

$$P_A + P_R = 1$$

$$P_A = P_C + P_E$$

$$P_C + P_E + P_R = 1$$

$P_A, P_E, P_R$  et  $P_C$  dépendent de  $\lambda_R$

## risque Bayésien

$$C^* = \int_R C^*(x) p(x) dx \quad \text{Avec } C^*(x) = C(d^*(x)|x)$$

$$C^* = \int_{R_A} C^*(x) p(x) dx + \int_{R_0} C^*(x) p(x) dx$$

Règle des coûts 0-1 :

$$C^*(x) = e^*(x) = 1 - \max_{i=1, \dots, K} P(\omega_i | x) \quad \text{pour } x \in R_A$$

Règle des coûts 0-1 :  $C^*(x) = e^*(x)$

$$C^* = \int_{R_A} e^*(x) p(x) dx + \int_{R_0} \lambda_R p(x) dx$$

$$C^* = P_E + \lambda_R P_R$$

$C^*$  = risque minimum = risque bayésien


## rapport de vraisemblance

$d^*(x) = 1$  si

$$\Lambda(x) = \frac{p(x | \omega_1)}{p(x | \omega_2)} > \frac{\lambda(\omega_1 | \omega_2) P(\omega_2)}{\lambda(\omega_2 | \omega_1) P(\omega_1)} = \eta$$

$d^*(x) = 2$  sinon

## probabilité d'erreur



$$\begin{aligned} P(\text{erreur}) &= P(X \in R_1, \omega_2) + P(X \in R_2, \omega_1) \\ &= P(X \in R_1 | \omega_2) P(\omega_2) + P(X \in R_2 | \omega_1) P(\omega_1) \\ &= \int_{R_1} p(x | \omega_2) P(\omega_2) dx + \int_{R_2} p(x | \omega_1) P(\omega_1) dx \end{aligned}$$

## Exemple : vérification d'identité

- problème à 2 classes

- $\omega_1$  : clients du système

- $\omega_2$  : imposteurs

- Décision : 
$$s(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \underset{\omega_2}{\overset{\omega_1}{><}} \eta$$

## erreurs de type I et II

$H_0$  - hypothèse nulle: absence d'imposteur

- $P_E^1$  : Erreur de type 1 (rejeter  $H_0$  de manière erronée): rejeter un client ou faux rejet (fausse alarme, faux positif)

- $P_E^2$  : Erreur de type 2 : (accepter  $H_0$  de manière erronée): accepter un imposteur ou fausse acceptation (détection manquée, faux négatif)

	$\omega_1$ : client	$\omega_2$ : imposteur
$d(x)=1$	correct	type 2
$d(x)=2$	type 1	correct

## Suite...

$$P_E^2 = P(\text{décider } \omega_1, \omega_2 \text{ est vrai}) \text{ prob. jointe}$$

$$P_E^2 = P(d(x)=1|\omega_2)P(\omega_2) = \int_{R_1} p(x|\omega_2)P(\omega_2)dx$$

$$P_E^2 = \int_{R_1} P(\omega_2|x)p(x)dx$$

$$P_E^1 = P(\text{décider } \omega_2, \omega_1 \text{ est vrai})$$

$$P_E^1 = \int_{R_2} p(x|\omega_1)P(\omega_1)dx = \int_{R_2} P(\omega_1|x)p(x)dx$$

$$P_E = P_E^1 + P_E^2$$

## vérification d'identité : FRR-FAR

- espace de représentation
- probabilités conditionnelles

Taux de faux rejet = FRR =  $P(d(x)=2|\omega_1 \text{ est vrai})$

Taux de fausse acceptation = FAR =  $P(d(x)=1|\omega_2 \text{ est vrai})$

$$FRR = \int_{R_2} p(x|\omega_1) dx$$

$$FAR = \int_{R_1} p(x|\omega_2) dx$$


$$P_E = P(\omega_1)FRR + P(\omega_2)FAR$$

## FAR-FRR : espace des scores


$$s(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \begin{matrix} > \eta \\ < \eta \end{matrix} \begin{matrix} \omega_1 \\ \omega_2 \end{matrix}$$

$$FRR = \int_{R_2} p(s|\omega_1) ds$$

$$FAR = \int_{R_1} p(s|\omega_2) ds$$



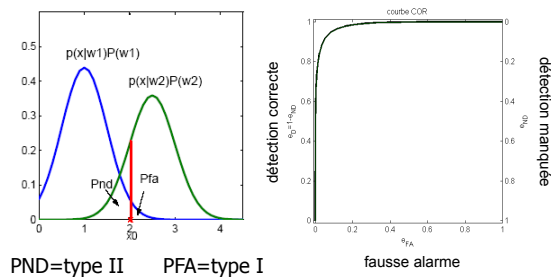
## EER : Equal Error rate




## Courbe ROC

- COR : Caractéristique Opérationnelle du Récepteur
  - $\omega_1$  : absence d'objet
  - $\omega_2$  : présence d'objet
- incrémentation du seuil de décision
  - courbe Probabilité détection correcte en fonction probabilité de fausse alarme

si  $x > x_0$  (seuil) alors présence de cible ( $\omega_2$ )




## Courbe ROC



aire sous la courbe ROC

## Courbe DET


[chollet]



L. Lékifman - Telecom ParisTech - SI 221 - 2010

46


## Zones de décision



L. Lékifman - Telecom ParisTech - SI 221 - 2010

47

## zone de rejet




$$P_{rejet} = \int_{R0} p(x) dx$$

L. Lékifman - Telecom ParisTech - SI 221

48



## zone de rejet



L. Likhoman - Telecom ParisTech - SI 221

49

## distributions normales

- $M$  : vecteur moyenne

classe  $\omega$

- $E[X|\omega]$

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_d \end{pmatrix}$$

$$M = \begin{pmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_d) \end{pmatrix}$$

- $\Sigma$ : matrice de covariance

classe  $\omega$

- $E[(X-M)(X-M)^T|\omega]$
- $\Sigma$  est symétrique définie positive

$$p(x|\omega) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} e^{-\frac{1}{2}(x-M)^T \Sigma^{-1} (x-M)}$$

L. Likhoman - Telecom ParisTech - SI 221

50

## distributions normales (suite)

- $\Sigma$ : matrice de covariance

- variance  $\sigma_i^2$  (caractéristique  $X_i$ )
- covariance  $\sigma_{ij}$  (caractéristiques  $X_i$  et  $X_j$ )

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{bmatrix}$$

$$\sigma_i^2 = E[(X_i - E(X_i))(X_i - E(X_i))]$$

$$\begin{aligned} \sigma_{ij} &= E[(X_i - E(X_i))(X_j - E(X_j))] \\ &= E(X_i X_j) - E(X_i)E(X_j) \end{aligned}$$

L. Likhoman - Telecom ParisTech - SI 221 - 2010

51


## ellipsoïde de Mahalanobis

### ■ lieu des points

$$U = \begin{bmatrix} X \\ Y \end{bmatrix}$$

$$(U - M)^t \Sigma^{-1} (U - M) = Cte$$

### ■ orientation



L. Likhoman - Telecom ParisTech - SI 221

52

## ellipsoïde de Mahalanobis

### ■ décomposition: $\Sigma$ symétrique

$$\Sigma = V^t * \Sigma_d * V$$

$$V: \text{matrice des vecteurs propres} \quad V = \begin{bmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{bmatrix}$$

$$\Sigma_d = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \quad \text{matrice diagonalisée}$$

$$\Sigma = R^{-1} * \Sigma_d * R$$

$$R: \text{matrice de passage de } (R) \text{ à } (R') \quad R = \begin{bmatrix} \cos \alpha & \sin \alpha \\ -\sin \alpha & \cos \alpha \end{bmatrix}$$

L. Likhoman - Telecom ParisTech - SI 221


53

## ellipsoïde de Mahalanobis

### ■ grand axe, petit axe

#### □ repère de l'ellipsoïde ( $R'$ )

$$\frac{X'^2}{\lambda_1} + \frac{Y'^2}{\lambda_2} = Cte$$




$$1/2 \text{ grand axe} : \propto \sqrt{\max(\lambda_1, \lambda_2)}$$

$$1/2 \text{ petit axe} : \propto \sqrt{\min(\lambda_1, \lambda_2)}$$

L. Likhoman - Telecom ParisTech - SI 221

54

## distributions normales (suite)



L. Likhoman - Telecom ParisTech - SI 221

55

---

---

---

---

---

---

---

---

## Conclusion : décision Bayésienne

- cadre d'application
  - Les distributions  $p(x|w_i)$ ,  $P(w_i)$  doivent être connues
  - Sinon, il faut pouvoir les estimer (#échantillons suffisant)
- avantages/inconvénients
  - Classification optimale
  - Mise en œuvre simple
  - Estimation peut être délicate
- complexité
  - paramètres des modèles de classe

L. Likhoman - Telecom ParisTech - SI 221 - 2010

56

---

---

---

---


---

---

---

---

## ellipsoïde de Mahalanobis



L. Likhoman - Telecom ParisTech - SI 221 - 2010

57

---

---

---

---


---

---

---

---

## 2 lois gaussiennes : frontière



$$\Sigma_i = \Sigma$$

$$P(\omega_1) = P(\omega_2)$$

L. Lékifman - Telecom ParisTech - SI 221 - 2010

58

---

---

---

---


---

---

---

---

## 2 lois gaussiennes : frontière



$$\Sigma_i = \Sigma \text{ diagonale} : \propto \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$P(\omega_1) = P(\omega_2)$$

L. Lékifman - Telecom ParisTech - SI 221 - 2010

59

---

---

---

---


---

---

---

---

## 4 classes (mêmes matrices de covariance)



L. Lékifman - Telecom ParisTech - SI 221 - 2010

60

---

---

---

---


---

---

---

---

## Frontières : hyperplans ou hyperquadriques



L. Lékérou - Telecom ParisTech - SI 221 - 2010

61

---

---

---

---


---

---

---

---

## cercle, ellipse



L. Lékérou - Telecom ParisTech - SI 221 - 2010

62

---

---

---

---

---

---

---

---

## Conclusion : décision Bayésienne

- cadre d'application
  - Les distributions  $p(x|w_i)$ ,  $P(w_i)$  doivent être connues
  - Sinon, il faut pouvoir les estimer (#échantillons suffisant)
- avantages/inconvénients
  - Classification optimale
  - Mise en œuvre simple
  - Estimation peut être délicate
- complexité
  - paramètres des modèles de classe

L. Lékérou - Telecom ParisTech - SI 221 - 2010

63

---

---

---

---

---

---

---

---